

# 신경망과 딥러닝

1. 딥러닝 소개

2. 신경망과 로지스틱 회귀

# 1. Intro


"AI is the new Electricity"

→ 인공지능은 전기처럼 앞으로 수많은 산업들을 크게 변화시킬 수 있다.

딥러닝(Deep Learning)은 인공지능의 한 부분으로, 오늘날 매우 중요해졌다.

딥러닝이란? 신경망을 학습시키는 것!

그럼 신경망이란?




## 2. 신경망(Neural Network)이란?

### Housing Price Prediction Example

6개의 house 샘플이 있고, 각 house의 size(feature)와, price(target)를 알고 있다고 하자.

✓ 선형 회귀(Linear Regression): 예측을 위한 어떤 직선(선형 방정식)을 학습



price는 음수가 될 수 없으니 특정 지점보다 작아지면 0으로 유지되도록 한다.

→ ReLU(Rectified Linear Unit) function

- Rectified: 0과 결괏값 중 큰 값을 취하는 것


## 2. 신경망(Neural Network)이란?

### Housing Price Prediction Example

이번에는 각 house의 feature가 4개라고 하자. - size, #bedrooms, postal code, wealth

#### ✓ 뉴런(Neuron)

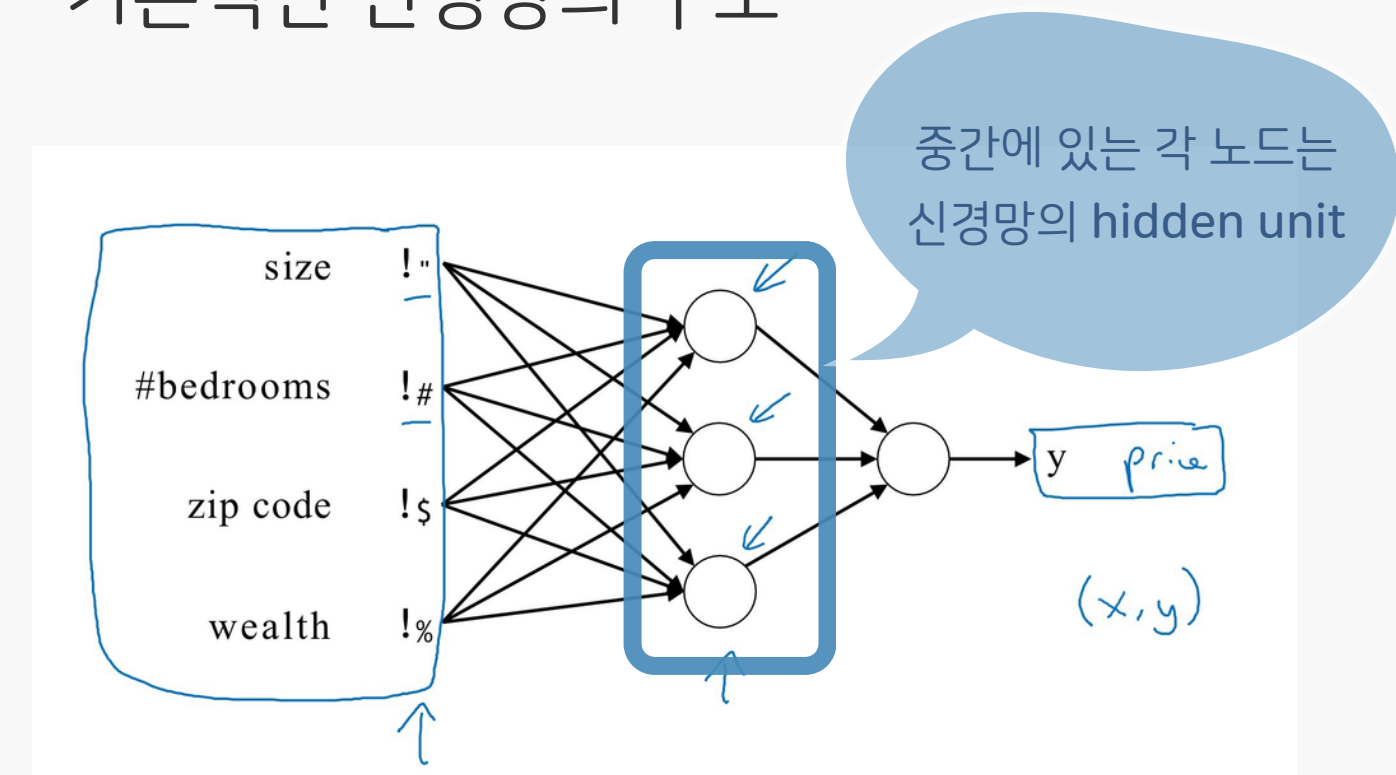
뉴런은 예측 함수를 계산하여,  
input  $x$ 에 따른 output  $y$ 를(예측 값) 반환한다.



#### ✓ 신경망(Neural Network, NN)

신경망은 뉴런이 많이 쌓인 형태이다.

-기본적인 신경망의 구조-



→ 충분한 train data( $x, y$ )를 주면 신경망은  $x \rightarrow y$ 로 연결하는 함수를 스스로 알아내고 학습한다.

### 3. 지도학습 + 신경망

지도학습은 신경망을 학습시키는 방식이 가장 유용하고 효과적이다.

#### 표준 신경망(Standard NN)

- house features로 price 예측 → 부동산
- 사용자 정보+광고로 사용자의 광고 클릭 예측 → 온라인 광고

#### 순환 신경망(Recurrent NN, RNN)

음성이나 언어 같은 시퀀스 데이터에는 RNN 사용

✓ 시퀀스 데이터(Sequence data): 데이터 간의 순서(의존성)이 있는 데이터

✓ 음성은 시퀀스 데이터 중에서도 시간의 흐름에 따라 재생되는 1차원 시계열 데이터(Time Series data)

- 음성으로 Text Transcript를 예측 → 음성 인식
- 한 언어를 다른 언어로 예측 → 번역


#### 합성곱 신경망(Convolutional NN, CNN)

이미지 데이터에는 CNN 사용

- 이미지가 어떤 종류인지 예측 → photo tagging

#### Custom/Hybrid 신경망

- 이미지+레이더 정보로 다른 차의 위치 예측 → 자율주행



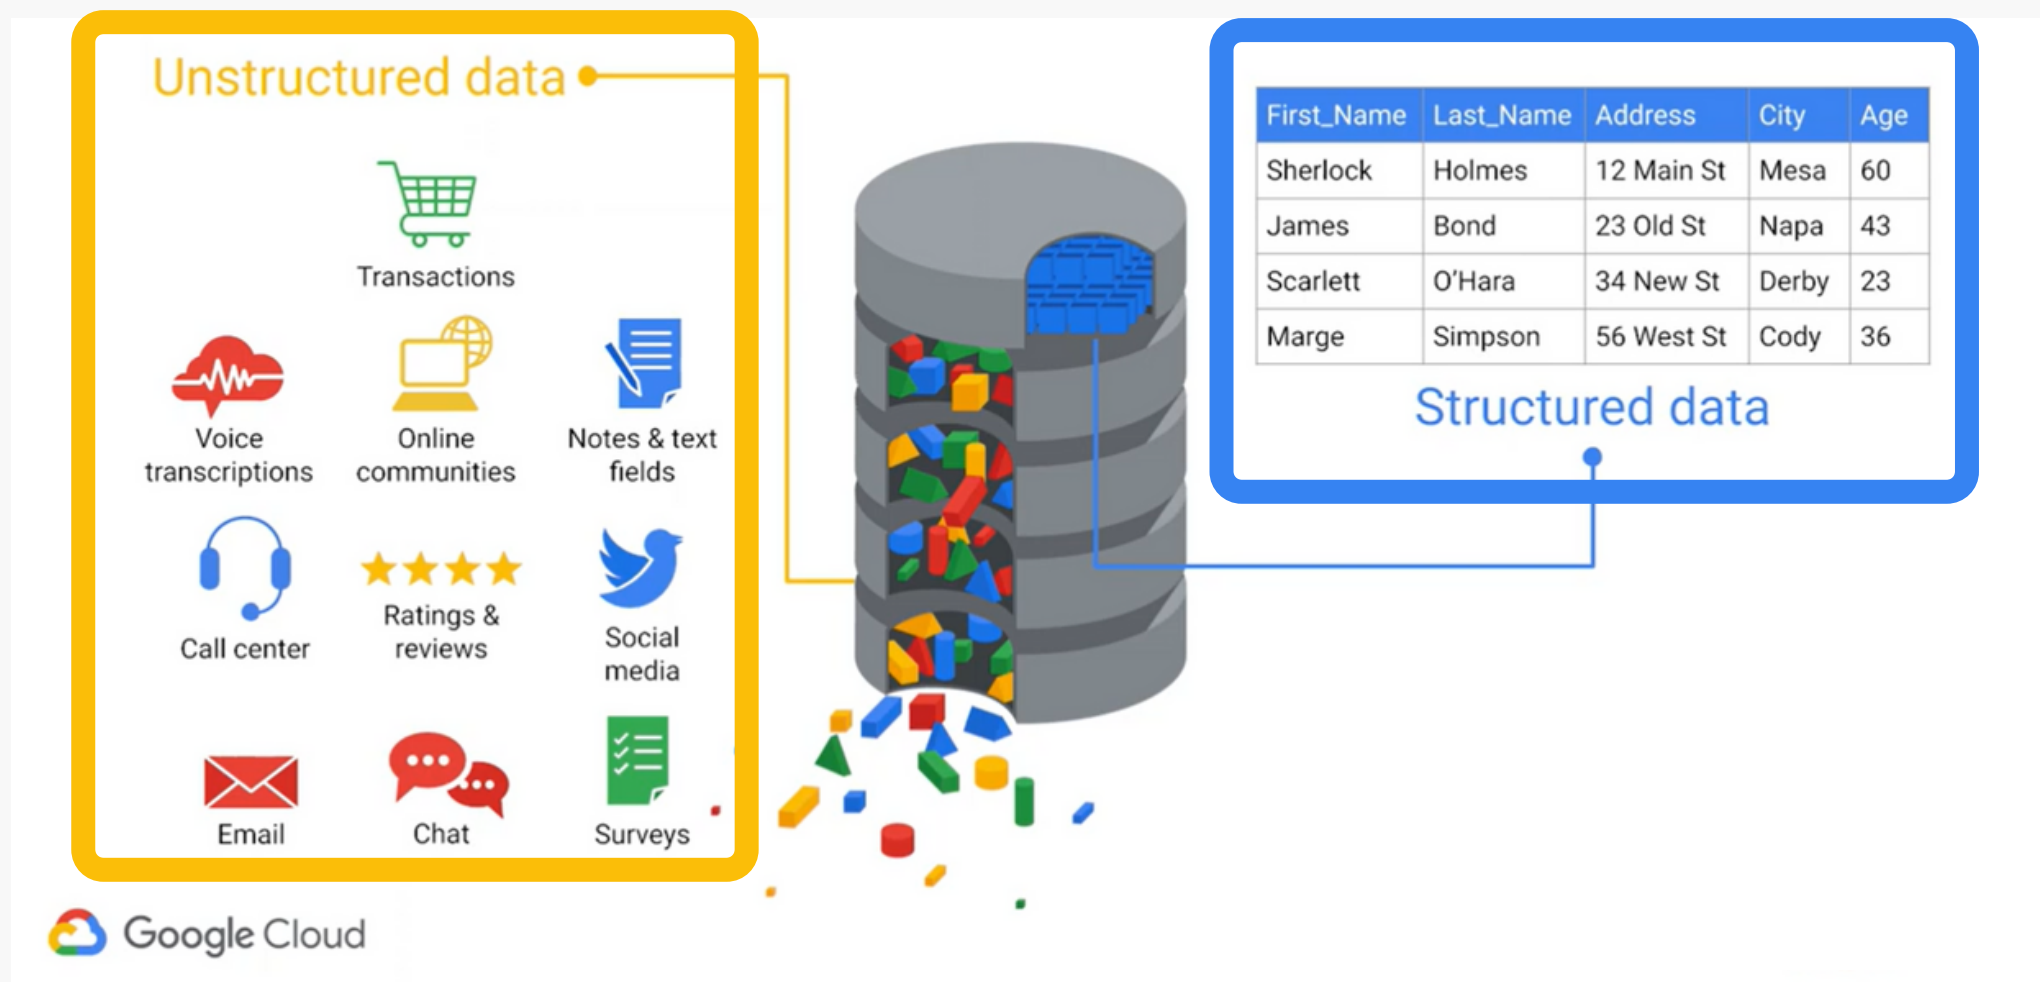
### 3. 지도학습 + 신경망

#### 비정형 데이터

데이터베이스로 표현하기 어려운  
텍스트, 이미지, 오디오 등의 데이터

#### 정형 데이터

어떤 구조로 이루어져 csv나  
데이터베이스에 저장하기 쉬운 데이터



→ 딥러닝의 발전으로 컴퓨터가 비정형 데이터를 더 잘 해석할 수 있게 되었다.

## 4. 딥러닝의 성장 동력

data, computation, algorithms의 “scale”이 딥러닝을 성장하게 한다.

### (1) data

train data의 양이 적을 때: ML 알고리즘과 신경망의 성능 차이가 크지 않다. → 구현 방법에 따라 성능이 달라진다.


train data의 양이 커질 수록: large NN의 성능이 높아진다.

### (2) computation

GPU 같이 전문화된 하드웨어나 더 빠른 네트워크 → 빠른 속도

### (3) algorithms

알고리즘 자체의 혁신 → 빠른 속도



신경망을 학습시키는 과정은 반복적이므로 계산 속도가 빠를수록 좋다.

오늘날...

많은 양의 data → 신경망의 성능이 높아진다.

computation, algorithms의 발전 → 학습 속도가 빨라진다.

→ 더 많이 테스트해 보고, 더 좋은 방법을 채택할 수 있다.

⇒ 지금까지도 딥러닝은 계속 발전하고 있다!



## ※ Notation

$m$ : 전체 dataset의 샘플 개수

- $m_{train}$ : train data의 샘플 개수
- $m_{test}$ : test data의 샘플 개수

$n = n_x$ : input feature 값의 개수(차원)

$n_y$ : output 값의 개수

$x^{(i)}$ :  $i$ 번째 샘플의  $x$  값

$y^{(i)}$ :  $i$ 번째 샘플의  $y$  값

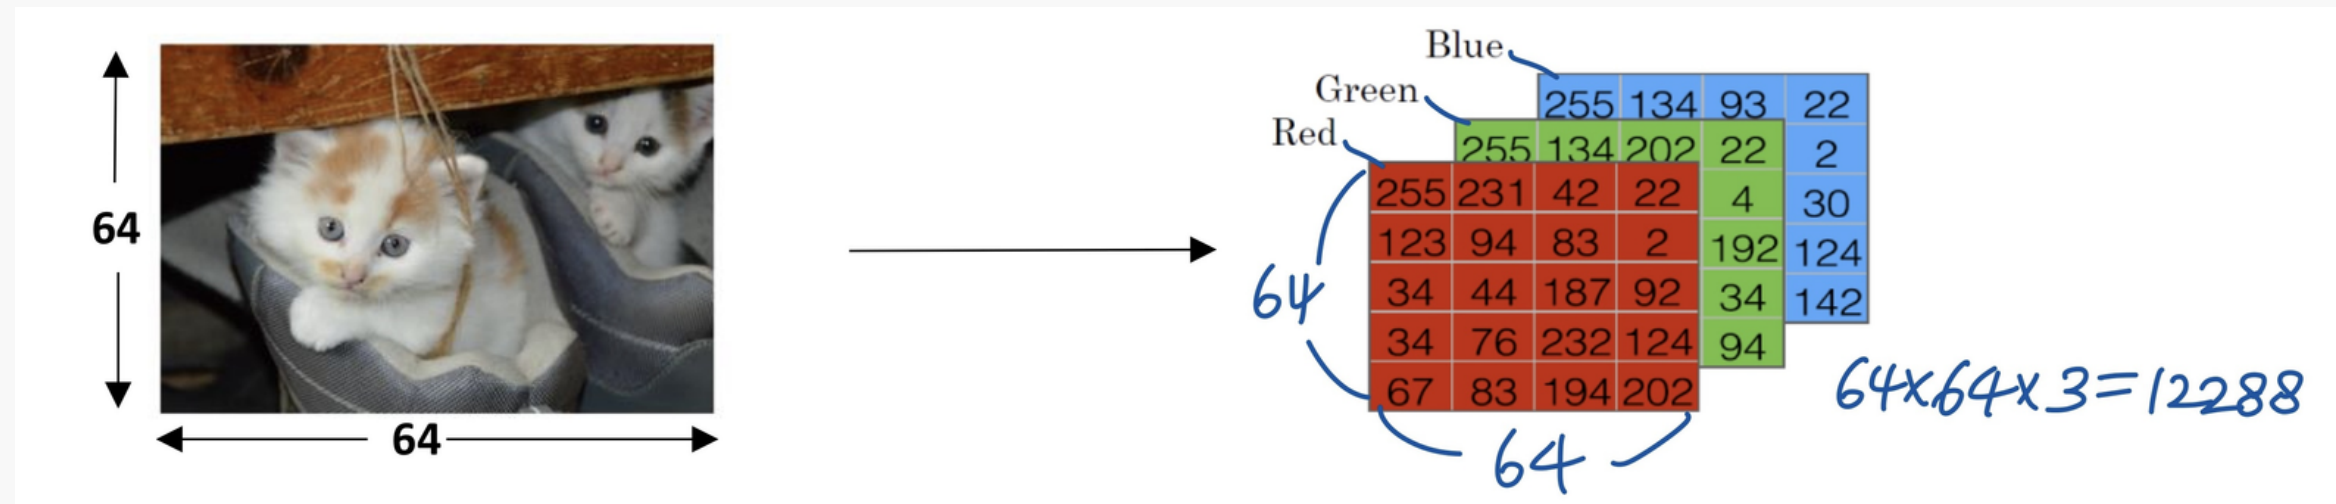
$\hat{y}$ :  $y$ 의 예측 값



## 5. 이진 분류

Cat(1) vs Non-Cat(0)

-이미지 데이터-



$$x = \begin{bmatrix} 255 \\ 231 \\ 42 \\ \vdots \\ 255 \\ 134 \\ 202 \\ \vdots \\ 255 \\ 134 \\ 93 \\ \vdots \end{bmatrix} \begin{matrix} \text{red } 64 \times 64 \\ \text{green } 64 \times 64 \\ \text{blue } 64 \times 64 \end{matrix}$$

- 이미지 데이터는 픽셀로 이루어진다. 각 픽셀에는 (R, G, B) 값이 포함된다.
  - E.g. 64\*64 크기의 이미지에는 총  $64 \times 64 \times 3 = 12288$ 개의 픽셀 값이 있다.

- 이미지 데이터의 픽셀 값을 하나의 열로 나열한다.
- input feature의 차원  
 $= n = 12288$

## 5. 이진 분류

Cat(1) vs Non-Cat(0)

train set  
 $(x, y)$

$$x \in \mathbb{R}^{n_x}, y \in \{0, 1\}$$

$m$  training examples :  $\{(\underline{x^{(1)}}), \underline{y^{(1)}}), (\underline{x^{(2)}}), \underline{y^{(2)}}), \dots, (\underline{x^{(m)}}), \underline{y^{(m)}})\}$

$$X = \begin{bmatrix} | & | & \dots & | \\ x^{(1)} & x^{(2)} & \dots & x^{(m)} \\ | & | & \dots & | \end{bmatrix}$$

$(n_x, m)$

↑ 각 sample

←  $m$

↑  $n_x$

$$Y = [y^{(1)} \ y^{(2)} \ \dots \ y^{(m)}]$$

$(1, m)$

- $X$ : 각 샘플을 열로 나열한 행렬
- $Y$ : 각 샘플의 target 값을 나열한 1차원 배열

## 6. Logistic Regression

✓ 이진 분류를 위한 로지스틱 회귀(Logistic Regression) 알고리즘

Given  $x$ , want  $\hat{y} = \frac{P(y=1|x)}{0 \leq \hat{y} \leq 1}$  y의 예측값 = y가 1일 확률  
 $x \in \mathbb{R}^{n_x}$  실수

Parameters:  $\underline{w} \in \mathbb{R}^{n_x}, \underline{b} \in \mathbb{R}$ .

Output:  $\hat{y} = \sigma(\underbrace{w^T x + b}_{z})$  시그모이드 함수 intercept term

y의 예측 값(y hat): y가 1일 확률

파라미터


- $w$ : 기울기, weight
- $b$ : 절편, threshold

Logistic Regression의 목표는 파라미터  $w, b$ 를 잘 학습시켜  $y$ 의 예측 값(y hat)을  $y$ 에 가깝게 예측하는 것이다.

직선 함수에 **시그모이드 함수**를 적용하여 결과값을 예측한다.

- 직선 함수 결과 값은 0~1 사이로 나오지 않아 이진 분류에 적절하지 않다.

## 6. Logistic Regression



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

If  $z$  large  $\sigma(z) \approx \frac{1}{1+0} = 1$

If  $z$  large negative number (small)

$$\sigma(z) = \frac{1}{1 + e^{-z}} \approx \frac{1}{1 + \text{Big num}} \approx 0$$

**시그모이드 함수**는 직선 함수  $z$ (직선 함수에서의 예측 값)이 커질수록 1에 수렴하고, 작아질수록 0에 수렴한다.

→ 예측 값을 0~1 사이로 만든다.

## 6. Logistic Regression

Given  $x$ ,  $\hat{y} = P(y = 1|x)$ , where  $0 \leq \hat{y} \leq 1$

The input features vector:  $x \in \mathbb{R}^{n_x}$ , where  $n_x$  is the number of features

The training label:  $y \in 0,1$

The weights:  $w \in \mathbb{R}^{n_x}$ , where  $n_x$  is the number of features

The threshold:  $b \in \mathbb{R}$

The output:  $\hat{y} = \sigma(w^T x + b)$

Sigmoid function:  $s = \sigma(w^T x + b) = \sigma(z) = \frac{1}{1 + e^{-z}}$

? 직선 함수의  $w^T$ (transpose of  $w$ )는 가중치  $w$ 를  $x$ 에 곱하기 위해 행으로 바꾸는 것

## 6. Logistic Regression

파라미터  $w, b$ 를 잘 학습시킨다는 건 어떤 의미일까?


좋은  $w, b$ 는 어떻게 찾아 나갈까?

→ Loss function, Cost function


→ Gradient Descent

1. 다음 중 ReLU function은 무엇인가요? \*


1점




☐ 옵션 1



☐ 옵션 2



☒ 옵션 3



☐ 옵션 4

-Remind-


ReLU(Rectified Linear Unit) function

- Rectified: 0과 결괏값 중 큰 값을 취하는 것



7. 강의에서 보았던 아래 그림의 x,y 축은 각각 어떤 것인가요? \*

1점



- ☐ x: 알고리즘의 성능, y: 데이터의 양
- ☐ x: 데이터의 양, y: 모델의 크기
- ☐ x: 알고리즘으로의 input, y: output
- ☒ x: 데이터의 양, y: 알고리즘의 성능

## -Remind-

train data의 양이 적을 때: ML 알고리즘과 신경망의 성능 차이가 크지 않다. → 구현 방법에 따라 성능이 달라진다.

train data의 양이 커질 수록: large NN의 성능이 높아진다.

